



**La finalidad de esta práctica es familiarizarse con el entorno HIVE.**

Vete haciendo capturas de pantalla de todos los pasos que vayas dando, acompañándolas de comentarios descriptivos de los mismos.

### INTRODUCCIÓN

A.- Continuaremos trabajando con el conjunto de datos **Movielens** de **Kaggle**:

<https://www.kaggle.com/datasets/prajitdatta/movielens-100k-dataset>

### CONTENIDO

#### APARTADO A

##### Práctica con HIVE

De modo similar a como hicimos con PIG, por cada uno de los *scripts* siguientes:


Prueba su ejecución tanto desde la consola de Hive

```
[maria_dev@sandbox-hdp ~]$ hive
log4j:WARN No such property [maxFileSize] in org.apache.log4j.DailyRollingFileAppender.

Logging initialized using configuration in file:/etc/hive/2.6.5.0-292/0/hive-log4j.properties
hive>
```

como desde Ambari Hive View 2.0.

- Muestra el contenido de los *scripts*.
- Muestra un ejemplo de su ejecución con la salida de los datos por pantalla tanto en la consola como desde el entorno de Ambari.
- Posteriormente guarda las consultas en un archivo y ejecútalas todas juntas desde la línea de comandos.



- 1.- Crea una base de datos que llamaremos movielens para almacenar las tablas necesarias. Para cada una de las consultas deberás crear previamente las tablas y cargar los datos necesarios para poder realizarlas.

```
Logging initialized using configuration in file:/etc/hive/2.6.5.0-292/0/hive-log4j.properties
hive> CREATE DATABASE movielens;
OK
T: Guardado en Este PC 376 seconds
hive>
```

```
hive> SHOW DATABASES;
OK
default
foodmart
movielens
Time taken: 0.017 seconds, Fetched: 3 row(s)
hive>
```

HIVE

QUERY
JOBS
TABLES
SAVED QUERIES
UDFs
SETTINGS

Worksheet1
+

DATABASE
Select or search database/schema

x default

foodmart

movielens

default

1

### Tablas necesarias PELICULAS, USUARIOS, VOTACIONES

**VOTOS:** u.data2.txt : user id , movie id , rating , timestamp. (AHORA SEPARADO POR COMAS)

**USUARIOS:** - u.user2.txt: user id , age , gender , occupation | (AHORA SEPARADO POR COMAS)

**PELICULAS:** - u.item2.txt: movie id | movie title | release date (SEPARADO POR TAB)

### CARGAMOS VOTOS

```
hive> CREATE EXTERNAL TABLE IF NOT EXISTS VOTOS (
>   user_id INT,
>   movie_id INT,
>   rating INT,
>   times_tamp INT
> )
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> STORED AS TEXTFILE;
OK
Time taken: 1.773 seconds
```

```
hive> LOAD DATA INPATH '/user/maria_dev/movielens/u.data2.txt'
> OVERWRITE INTO TABLE VOTOS;
Loading data to table movielens.votos
chgrp: changing ownership of 'hdfs://sandbox-hdp.hortonworks.com:8020/apps/hive/warehouse/movielens.db/votos/u.data2.txt': User null does not belong to hadoop
Table movielens.votos stats: [numFiles=1, numRows=0, totalSize=1979173, rawDataSize=0]
OK
Time taken: 1.645 seconds
hive> |
```

### CARGAMOS LOS USUARIOS

```
hive> CREATE TABLE IF NOT EXISTS USUARIOS (
>     user_id INT,
>     age INT,
>     gender STRING,
>     occupation STRING
> )
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> STORED AS TEXTFILE;
```

```
hive> LOAD DATA INPATH '/user/maria_dev/movielens/u.user2.txt'
>     OVERWRITE INTO TABLE USUARIOS;
Loading data to table movielens.usuarios
```

## CARGAMOS LAS PELICULAS

```
hive> CREATE TABLE IF NOT EXISTS PELICULAS(
>     movie_id INT,
>     title STRING,
>     release_year INT
> )
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY '\t'
> STORED AS TEXTFILE;
```

OK

Time taken: 0.741 seconds

```
hive> LOAD DATA INPATH '/user/maria_dev/movielens/u.item2.txt'
>     OVERWRITE INTO TABLE PELICULAS;
```

# HIVE

[QUERY](#)
[JOBS](#)
[TABLES](#)
[SAVED QUERIES](#)
[UDFs](#)
[SETTINGS](#)

DATABASE

Select or search database/schema

movielens

TABLES | 3

↺

+

Search

🔍

películas

usuarios

votos

TABLE > VOTOS

COLUMNS

DDL

STORAGE INFORMATION

DETAILED INFORMATION

AUTHORIZATION

COLUMN NAME	COLUMN TYPE	COMMENT
user_id	int	
movie_id	int	
rating	int	
times_tamp	int	

## 2.- Encontrar las 10 ocupaciones más frecuentes entre los votantes

```
hive> SELECT occupation, COUNT(*) AS total
> FROM USUARIOS
> GROUP BY occupation
> ORDER BY total DESC
> LIMIT 10;|
```

VERTICES	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1 .....	SUCCEEDED	1	1	0	0	0	0
Reducer 2 .....	SUCCEEDED	1	1	0	0	0	0
Reducer 3 .....	SUCCEEDED	1	1	0	0	0	0

VERTICES: 03/03 [=====>>] 100% ELAPSED TIME: 4.16 s

```
OK
student 196
other 105
educator 95
administrator 79
engineer 67
programmer 66
librarian 51
writer 45
executive 32
scientist 31
```

## 3.- Y luego el número de hombres y mujeres

```
hive> SELECT gender, COUNT(*)
> FROM USUARIOS
> GROUP BY gender;
```

VERTICES	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1 .....	SUCCEEDED	1	1	0	0	0	0
Reducer 2 .....	SUCCEEDED	1	1	0	0	0	0

VERTICES: 02/02 [=====>>] 100% ELAPSED TIME: 3.82 s

```
OK
F 273
M 670
Time taken: 4.594 seconds, Fetched: 2 row(s)
```

## 4.- Muestra la edad media por géneros.

```
hive> SELECT gender, AVG(age)
> FROM USUARIOS
> GROUP BY gender;
```

```

-----
VERTICES      STATUS  TOTAL  COMPLETED  RUNNING  PENDING  FAILED  KILLED
-----
Map 1 .....  SUCCEEDED    1         1         0         0         0         0
Reducer 2 ..... SUCCEEDED    1         1         0         0         0         0
-----
VERTICES: 02/02 [=====>>] 100% ELAPSED TIME: 2.87 s
-----
OK
F      33.81318681318681
M      34.149253731343286
Time taken: 3.568 seconds, Fetched: 2 row(s)
hive>

```

## 5.- Muestra la edad media por ocupaciones.

```

hive> SELECT occupation, AVG(age)
> FROM USUARIOS
> GROUP BY occupation
> ORDER BY occupation;

```

```

-----
VERTICES      STATUS  TOTAL  COMPLETED  RUNNING  PENDING  FAILED  KILLED
-----
Map 1 .....  SUCCEEDED    1         1         0         0         0         0
Reducer 2 ..... SUCCEEDED    1         1         0         0         0         0
Reducer 3 ..... SUCCEEDED    1         1         0         0         0         0
-----
VERTICES: 03/03 [=====>>] 100% ELAPSED TIME: 3.08 s
-----
OK
administrator 38.74683544303797
artist 31.392857142857142
doctor 43.57142857142857
educator 42.01052631578948
engineer 36.38805970149254
entertainment 29.22222222222222
executive 38.71875
healthcare 41.5625
homemaker 32.57142857142857
lawyer 36.75
librarian 40.0
marketing 37.61538461538461
none 26.555555555555557
other 34.523809523809526
programmer 33.121212121212125
retired 63.07142857142857
salesman 35.666666666666664
scientist 35.54838709677419
student 22.081632653061224
technician 33.148148148148145
writer 36.31111111111111
Time taken: 3.789 seconds, Fetched: 21 row(s)
hive>

```

6.- Encontrar las cinco películas (código, título y número de votos) más votadas (recuento de votos, no media).

```
hive> SELECT r.movie_id, i.title, COUNT(*) AS num_votos
> FROM VOTOS r
> JOIN PELICULAS i ON r.movie_id = i.movie_id
> GROUP BY r.movie_id, i.title
> ORDER BY num_votos DESC
> LIMIT 5;
```

VERTICES	STATUS	TOTAL	COMPLETED	RUNNING	PENDING	FAILED	KILLED
Map 1 .....	SUCCEEDED	1	1	0	0	0	0
Map 4 .....	SUCCEEDED	1	1	0	0	0	0
Reducer 2 .....	SUCCEEDED	1	1	0	0	0	0
Reducer 3 .....	SUCCEEDED	1	1	0	0	0	0

VERTICES: 04/04 [=====>>] 100% ELAPSED TIME: 5.23 s

```
OK
50      Star Wars      583
258     Contact 509
100     Fargo 508
181     Return of the Jedi 507
294     Liar Liar 485
Time taken: 6.213 seconds, Fetched: 5 row(s)
```